BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC THÀNH PHỐ HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN

ĐỒ ÁN MÔN HỌC

TRUY HỒI THÔNG TIN

ĐỀ TÀI: KẾT HỢP TÌM KIẾM VÀ GỢI Ý PHIM THEO MÔ TẢ NGƯỜI DÙNG

Giảng viên hướng dẫn: **ThS. Nguyễn Thị Phương Trang**

Sinh viên thực hiện:

1. Đoàn Thanh Sang 23DH113038
2. Trần Lâm Hồng Liên 23DH111855
3. Trương Gia Nghi 23DH114778

Thành phố Hồ Chí Minh, 8 tháng 4 năm 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC THÀNH PHỐ HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN

ĐỒ ÁN MÔN HỌC

TRUY HỒI THÔNG TIN

ĐỀ TÀI: KẾT HỢP TÌM KIẾM VÀ GỢI Ý PHIM THEO MÔ TẢ NGƯỜI DÙNG

Giảng viên hướng dẫn: **ThS. Nguyễn Thị Phương Trang**

Sinh viên thực hiện:

1. Đoàn Thanh Sang 23DH113038
2. Trần Lâm Hồng Liên 23DH111855
3. Trương Gia Nghi 23DH114778

Thành phố Hồ Chí Minh, 8 tháng 4 năm 2026

BẢNG ĐÁNH GIÁ MỨC ĐỘ HOÀN THÀNH

Họ tên	**MSSV**	**Công việc được giao**	**Mức độ hoàn thành**
Đoàn Thanh Sang	23DH113038	[1] Cài đặt các mô hình truy hồi [2] Viết báo cáo phần mô hình truy hồi [3] Giao diện streamlit	40%
Trương Gia Nghi	23DH114778	[1] Chuẩn bị, tiền xử lý và lưu trữ tập dataset [2] Viết báo cáo phần mô tả hệ thống [3] Viết phần thiết lập các cài đặt	30%
Trần Lâm Hồng Liên	23DH111855	[1] Cài đặt code phần đánh giá mô hình [2] Viết báo cáo phần đánh giá mô hình và kết quả thực nghiệm [3] Viết phần chương 5 kết luận	30%

MỤC LỤC

KHOA CÔNG NGHỆ THÔNG TIN 1
KHOA CÔNG NGHỆ THÔNG TIN 1
CHƯƠNG 1. GIỚI THIỆU 1
1.1. Giới thiệu đề tài 1
1.2. Nội dung thực hiện 2
1.3. Giới hạn đề tài 3
1.4. Bố cục báo cáo 5
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT 6
2.1. Các khái niệm cơ bản 6
2.1.1. Trọng số TF-IDF (Term Frequency – Inverse Document Frequency) 6
2.1.2. Phân tích ngữ nghĩa tiềm ẩn (LSA) và Truncated SVD 7
2.1.3. Độ tương đồng Cosine (Cosine Similarity) và Chuẩn hóa L2 7
2.1.4. Tối ưu truy xuất với FAISS (IVFFlat Index) 8
2.1.5. Công thức đánh giá phổ biến (IMDB Weighted Rating) 8
2.1.6. Cơ chế nội suy trọng số (Hybrid Blending) 9
2.1.7. Các độ đo đánh giá trong Truy hồi thông tin (IR Metrics) 9
2.2. Các công trình nghiên cứu liên quan 11
2.2.1. Kết hợp Sparse và Dense Retrieval trong tìm kiếm chính xác cao (2023) 11
2.2.2. Ứng dụng FAISS trong hệ thống gợi ý thời gian thực (2022) 11
2.2.3. Ứng dụng LSA (Truncated SVD) trong phân tích ngữ nghĩa phim (2021) 11
2.2.4. Tăng cường hiệu quả bằng Metadata và Feature Weighting (2024) 12
2.2.5. Explainable AI trong hệ thống gợi ý (2023) 12
CHƯƠNG 3. THIẾT KẾ TRIỂN KHAI HỆ THỐNG 13
3.1. Tổng quan phương pháp hiện thực 13
3.1.1. Phương pháp xử lý dữ liệu hướng thực thể (Entity-Centric Data Engineering) 13
3.1.2. Phương pháp truy hồi thông tin lai (Hybrid Retrieval Approach) 14
3.1.3. Phương pháp tái xếp hạng và heuristic (Re-ranking & Heuristics) 14
3.1.4. Khung kiến trúc ứng dụng (Application Framework) 15
3.2. Mô tả hệ thống (System Overview) 16
3.2.1. Pipeline tổng thể: 16
3.2.2. Mô tả từng module 16
3.3. Công cụ hiện thực 19
3.4. Tập dữ liệu 20
3.4.1. Nguồn gốc và Thu thập dữ liệu (Data Sources & Collection) 20
3.4.2. Giai đoạn tiền xử lý thống kê và gộp dữ liệu (Data Aggregation & Merging) 20

3.4.3. Giai đoạn chuẩn hóa, Làm sạch và Sinh Đặc trưng (Data Cleaning & Feature Engineering) 22
3.5. Mô hình truy hồi 25
CHƯƠNG 4. THỰC NGHIỆM 29
4.1. Mô tả dataset 29
4.1.1. Từ điển dữ liệu (Data Dictionary) 29
4.1.2. Bảng dữ liệu mẫu (Data Representation Sample) 30
4.2. Thiết lập các cài đặt 31
4.3. Đánh giá mô hình 33
4.3.1. Phương pháp đánh giá 33
4.3.2. Các độ đo sử dụng 34
4.3.3. Kịch bản so sánh mô hình 35
4.4. Kết quả thực nghiệm 36
4.4.1. Kết quả tổng quan 36
4.4.2. Phân tích theo loại truy vấn (Hybrid model) 36
4.4.3. Đánh giá chung 37
4.5. Phân tích và thảo luận kết quả 37
4.5.1. So sánh giữa các mô hình 37
4.5.2. Đánh giá về hiệu năng hệ thống 38
4.5.3. Nhận xét tổng hợp 38
CHƯƠNG 5. KẾT LUẬN 40
5.1. Nhận xét kết quả đề tài 40
5.2. Ưu – nhược điểm của đề tài 40
5.2.1. Ưu điểm 40
5.2.2. Nhược điểm 41
5.3. Hướng phát triển 41
TÀI LIỆU THAM KHẢO 42

DANH MỤC HÌNH ẢNH

Hình 1. Sơ đồ Pipeline Luồng Xử lý Dữ liệu..... 16
Hình 2. Sơ đồ luồng thuật toán hợp nhất tập dữ liệu MovieLens và TMDB. 21
Hình 3. Sơ đồ quá trình làm sạch, chuẩn hóa và sinh đặc trưng văn bản..... 23
Hình 4. Sơ đồ kiến trúc mô hình truy hồi lai 26

DANH MỤC BẢNG BIỂU

Table 1. Các công cụ và thư viện cấu thành hệ thống 19
Table 2. Bảng các thuộc tính của dataset movies_processed.csv 29
Table 3. Bảng dữ liệu mẫu của tập dataset movies_processed.csv 31
Table 4. Bảng so sánh hiệu năng giữa các mô hình 36
Table 5. Hiệu năng theo loại truy vấn 37

CHƯƠNG 1. GIỚI THIỆU

1.1. Giới thiệu đề tài

Trong bối cảnh các nền tảng phát trực tuyến phát triển mạnh mẽ, số lượng phim ảnh ngày càng gia tăng đã dẫn đến hiện tượng *quá tải thông tin* (Information Overload), gây khó khăn cho người dùng trong việc tìm kiếm nội dung phù hợp. Trên thực tế, người dùng thường không nhớ chính xác tên phim mà chỉ mô tả nhu cầu thông qua nội dung, bối cảnh hoặc một số đặc điểm liên quan.

Tuy nhiên, các hệ thống tìm kiếm truyền thống chủ yếu dựa trên cơ chế so khớp từ khóa (keyword-based matching), do đó còn hạn chế trong việc xử lý ngữ nghĩa của truy vấn. Điều này làm giảm hiệu quả truy hồi khi người dùng sử dụng ngôn ngữ tự nhiên hoặc các cách diễn đạt linh hoạt. Xuất phát từ nhu cầu đó, đề tài **"Kết hợp tìm kiếm và gợi ý phim theo mô tả người dùng"** được lựa chọn nhằm nâng cao khả năng hiểu và đáp ứng truy vấn của người dùng.

Để giải quyết bài toán, hệ thống áp dụng kết hợp các kỹ thuật trong lĩnh vực truy hồi thông tin và xử lý ngôn ngữ tự nhiên. Cụ thể, dữ liệu được tiền xử lý bằng Pandas và NumPy; nội dung văn bản được biểu diễn thông qua mô hình TF-IDF kết hợp với phân tích ngữ nghĩa tiềm ẩn (Latent Semantic Analysis – LSA); đồng thời sử dụng FAISS để thực hiện tìm kiếm vector hiệu năng cao. Hệ thống được triển khai dưới dạng ứng dụng web sử dụng Streamlit và tích hợp dữ liệu từ các nguồn bên ngoài.

Trên cơ sở đó, hệ thống có khả năng thực hiện tìm kiếm lai thông qua cơ chế **kết hợp tuyến tính có trọng số (hybrid scoring)** giữa tìm kiếm từ khóa và tìm kiếm ngữ nghĩa, đồng thời tích hợp chức năng gợi ý phim dựa trên độ tương đồng nội dung. Ngoài ra, hệ thống còn cung cấp giao diện trực quan và khả năng giải thích kết quả (Explainable AI), góp phần nâng cao hiệu quả tìm kiếm và trải nghiệm người dùng.

1.2. Nội dung thực hiện

Để đạt được các mục tiêu đã đề ra, đề tài xây dựng một quy trình xử lý khép kín (end-to-end pipeline), bắt đầu từ dữ liệu thô và kết thúc bằng một ứng dụng web hoàn chỉnh. Các nội dung thực hiện chính bao gồm:

1. Thu thập và tiền xử lý dữ liệu (Data Engineering Pipeline)

- Xây dựng module tự động thu thập và hợp nhất dữ liệu từ hai nguồn chính là MovieLens (đánh giá, nhãn người dùng) và TMDB (diễn viên, đạo diễn, nội dung phim) thông qua khóa liên kết *tmdbId*.
- Thực hiện làm sạch và chuẩn hóa dữ liệu: xử lý cấu trúc JSON, chuẩn hóa văn bản (chuyển về chữ thường, loại bỏ ký tự đặc biệt) và tính toán độ phổ biến của phim (Weighted Rating).
- Xây dựng biểu diễn dữ liệu đầu vào bằng cách kết hợp nhiều trường thông tin (tên phim, thể loại, diễn viên, đạo diễn, mô tả), đồng thời áp dụng cơ chế gán trọng số nhằm tăng vai trò của các thuộc tính quan trọng.

2. Xây dựng không gian vector (Vectorization & LSA)

- Áp dụng mô hình TF-IDF để biểu diễn văn bản dưới dạng vector đặc trưng, phản ánh mức độ quan trọng của từ khóa.
- Sử dụng kỹ thuật Truncated SVD để giảm chiều dữ liệu và xây dựng không gian ngữ nghĩa tiềm ẩn (Latent Semantic Analysis – LSA), giúp hệ thống nắm bắt được mối quan hệ ngữ nghĩa giữa các từ.

3. Tối ưu truy xuất với FAISS (Vector Indexing)

- Tích hợp thư viện FAISS để thực hiện tìm kiếm tương đồng vector với hiệu năng cao.
- Chuẩn hóa vector và xây dựng cấu trúc chỉ mục phù hợp, cho phép truy xuất các vector gần nhất trong thời gian ngắn, đáp ứng yêu cầu xử lý trên tập dữ liệu lớn.

4. Xây dựng động cơ tìm kiếm lai (Hybrid Search Engine)

- Phát triển cơ chế **kết hợp tuyến tính có trọng số** giữa hai phương pháp: tìm kiếm theo từ khóa (TF-IDF) và tìm kiếm theo ngữ nghĩa (LSA + FAISS).
- Áp dụng bước tái xếp hạng (re-ranking) dựa trên các yếu tố bổ sung như điểm đánh giá và độ phổ biến nhằm cải thiện chất lượng danh sách kết quả.

5. Xây dựng hệ gợi ý phim (Recommender System)

- Triển khai phương pháp lọc theo nội dung (Content-Based Filtering) dựa trên độ tương đồng cosine giữa các phim.
- Bổ sung các luật kinh nghiệm nhằm cải thiện chất lượng đề xuất, như ưu tiên các phim cùng series, cùng đạo diễn hoặc có sự trùng lặp về diễn viên.

6. Đánh giá hệ thống (Evaluation)

- Xây dựng tập dữ liệu kiểm thử với nhiều loại truy vấn khác nhau (theo nội dung, diễn viên, thể loại, v.v.).
- Đánh giá hiệu năng của các mô hình (TF-IDF, LSA, Hybrid) thông qua các độ đo chuẩn trong truy hồi thông tin như Precision, Recall, MRR và NDCG.

7. Xây dựng giao diện người dùng (Web Application & Explainable AI)

- Phát triển giao diện web bằng Streamlit, hỗ trợ tương tác trực tiếp và cấu hình tham số theo thời gian thực.
- Tích hợp chức năng hiển thị thông tin phim, poster và trailer thông qua API bên ngoài.
- Cung cấp cơ chế giải thích kết quả (Explainable AI), giúp người dùng hiểu được lý do hệ thống đưa ra các đề xuất.

1.3. Giới hạn đề tài

Mặc dù hệ thống đã được xây dựng với nhiều kỹ thuật nhằm nâng cao hiệu quả truy hồi và xử lý ngữ nghĩa, đề tài vẫn tồn tại một số hạn chế nhất định do giới hạn về dữ liệu và tài nguyên tính toán. Cụ thể như sau:

1. Giới hạn về thuật toán và mô hình

- **Chưa hỗ trợ cá nhân hóa (Collaborative Filtering):** Hệ thống gợi ý hiện tại được xây dựng dựa trên phương pháp lọc theo nội dung (Content-Based Filtering), sử dụng thông tin mô tả của phim để tính toán độ tương đồng. Do đó, hệ thống chưa khai thác được hành vi người dùng (lịch sử xem, lượt tương tác), dẫn đến khả năng cá nhân hóa còn hạn chế.
- **Sử dụng mô hình ngôn ngữ truyền thống:** Hệ thống áp dụng TF-IDF kết hợp với LSA (SVD) để biểu diễn và xử lý văn bản, thay vì các mô hình học sâu hiện đại như BERT hoặc Transformer. Vì vậy, khả năng hiểu ngữ nghĩa phức tạp hoặc các truy vấn dài vẫn còn hạn chế ở một mức độ nhất định.

2. Giới hạn về dữ liệu và khả năng cập nhật

- **Dữ liệu tĩnh (Static Dataset):** Hệ thống được xây dựng trên tập dữ liệu đã được tổng hợp từ MovieLens và TMDB, chưa hỗ trợ cơ chế cập nhật tự động theo thời gian thực. Khi có dữ liệu mới, cần thực hiện lại toàn bộ quy trình tiền xử lý và xây dựng mô hình.
- **Giới hạn về ngôn ngữ:** Dữ liệu đầu vào chủ yếu ở dạng tiếng Anh, đồng thời quá trình tiền xử lý sử dụng bộ từ dừng (stopwords) tiếng Anh. Do đó, hệ thống hoạt động hiệu quả nhất với các truy vấn bằng tiếng Anh, và có thể giảm độ chính xác khi xử lý các ngôn ngữ khác.

3. Sự phụ thuộc vào hệ thống bên thứ ba

- Hệ thống sử dụng API từ TMDB để hiển thị thông tin hình ảnh và áp dụng cơ chế truy xuất dữ liệu từ YouTube để cung cấp trailer. Do đó, khả năng hoạt động của một số chức năng phụ thuộc vào độ ổn định của các dịch vụ bên ngoài, cũng như các giới hạn về tốc độ truy cập (rate limiting) hoặc thay đổi trong cấu trúc dữ liệu.

1.4. Bố cục báo cáo

Báo cáo được tổ chức theo cấu trúc logic, trình bày tuần tự từ cơ sở lý thuyết đến thiết kế, triển khai và đánh giá hệ thống. Nội dung được chia thành 5 chương chính như sau:

- **Chương 1. Giới thiệu**: Trình bày bối cảnh, lý do lựa chọn đề tài, các công nghệ được sử dụng và mục tiêu hướng đến. Đồng thời, chương này cũng nêu rõ phạm vi và giới hạn của đề tài.
- **Chương 2. Cơ sở lý thuyết**: Trình bày các nền tảng lý thuyết liên quan, bao gồm mô hình biểu diễn văn bản TF-IDF, phân tích ngữ nghĩa tiềm ẩn (LSA), phương pháp tìm kiếm tương đồng vector (FAISS) và nguyên lý của hệ gợi ý theo nội dung. Ngoài ra, chương này cũng đề cập đến một số nghiên cứu liên quan.
- **Chương 3. Thiết kế và triển khai hệ thống:** Mô tả kiến trúc tổng thể và quy trình xử lý của hệ thống, bao gồm các bước thu thập, tiền xử lý dữ liệu, xây dựng mô hình tìm kiếm lai và hệ gợi ý. Đồng thời trình bày cách thức triển khai giao diện người dùng.
- **Chương 4. Thực nghiệm và đánh giá:** Trình bày thiết lập thực nghiệm, phương pháp xây dựng tập dữ liệu đánh giá và các độ đo sử dụng như Precision, Recall, MRR và NDCG. Kết quả được phân tích nhằm đánh giá hiệu quả của hệ thống.
- **Chương 5. Kết luận và hướng phát triển**: Tổng kết các kết quả đạt được, nêu ra những hạn chế còn tồn tại và đề xuất các hướng cải tiến trong tương lai.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Các khái niệm cơ bản

Để xây dựng hệ thống truy hồi và gợi ý phim theo hướng lai (Hybrid Search & Recommendation), đề tài dựa trên nền tảng của các phương pháp trong lĩnh vực **Xử lý ngôn ngữ tự nhiên (NLP)**, **Truy hồi thông tin (Information Retrieval)** và **Hệ thống gợi ý (Recommender Systems)**. Các kỹ thuật chính được trình bày như sau:

2.1.1. Trọng số TF-IDF (Term Frequency – Inverse Document Frequency)

TF-IDF là phương pháp biểu diễn văn bản dưới dạng vector, cho phép định lượng mức độ quan trọng của một từ trong tài liệu so với toàn bộ tập dữ liệu.

$$TF - IDF(t, d, D) = TF(t, d) \times IDF(t, D)$$

Trong đó:

- t (Term): Từ khóa hoặc cụm từ cần xét trong văn bản.
- d (Document): Một tài liệu cụ thể; trong đề tài là nội dung của một bộ phim.
- D (Corpus): Toàn bộ tập hợp các tài liệu (tức toàn bộ danh sách phim).
- $TF(t, d)$ (Term Frequency): Tần suất xuất hiện của từ ttt trong tài liệu d → Phản ánh mức độ quan trọng của từ trong *chính tài liệu đó*.
- $IDF(t, D)$ (Inverse Document Frequency): Mức độ hiếm của từ ttt trong toàn bộ tập D → Giảm trọng số các từ phổ biến, tăng trọng số các từ đặc trưng.

Công thức tính IDF:

$$IDF(t, D) = \log\left(\frac{N}{DF(t)}\right)$$

Trong đó:

- N: Tổng số tài liệu trong tập DDD

- $DF(t)$: Số tài liệu có chứa từ ttt

→ Thành phần này giúp giảm ảnh hưởng của các từ phổ biến (ví dụ: “movie”, “film”) và làm nổi bật các từ mang tính đặc trưng.

2.1.2. Phân tích ngữ nghĩa tiềm ẩn (LSA) và Truncated SVD

Để khắc phục hạn chế của TF-IDF trong việc không nắm bắt được ngữ nghĩa, phương pháp **Latent Semantic Analysis (LSA)** sử dụng kỹ thuật **Truncated SVD** nhằm giảm chiều dữ liệu và phát hiện các chủ đề ẩn.

$$A \approx U_k \sigma_k V_k^T$$

Trong đó:

- A: Ma trận TF-IDF ban đầu (m×nm \times nm×n), biểu diễn mối quan hệ giữa tài liệu và từ vựng.
- k: Số chiều rút gọn (số chủ đề ẩn), chọn $k = 300$ trong hệ thống.
- U_k: Ma trận thể hiện mối quan hệ giữa tài liệu và các chủ đề ẩn.
- σ_k: Ma trận đường chéo chứa mức độ quan trọng của từng chủ đề.
- V_k^T: Ma trận thể hiện mối quan hệ giữa từ vựng và các chủ đề ẩn.

2.1.3. Độ tương đồng Cosine (Cosine Similarity) và Chuẩn hóa L2

Để đo mức độ tương đồng giữa truy vấn và tài liệu, hệ thống sử dụng độ đo Cosine Similarity, dựa trên góc giữa hai vector biểu diễn văn bản. Phương pháp này không phụ thuộc vào độ dài của văn bản.

$$Cosine(A, B) = \frac{A \cdot B}{\|A\| \, \|B\|}$$

Trong đó A là vector truy vấn và B là vector tài liệu.

Để tối ưu cho quá trình tính toán, hệ thống áp dụng **chuẩn hóa L2**, đưa độ dài các vector về 1 ($\|A\| = \|B\| = 1$). Khi đó, Cosine Similarity được rút gọn thành tích vô hướng:

$$Cosine(A, B) = A \cdot B$$

2.1.4. Tối ưu truy xuất với FAISS (IVFFlat Index)

Khi số lượng dữ liệu lớn, việc tính toán Cosine theo phương pháp vét cạn có độ phức tạp $O(N)$ là không hiệu quả. FAISS giải quyết vấn đề này bằng cách phân cụm vector và chỉ tìm kiếm trong các cụm gần nhất.

$$N_{list} = \max(50, 4\sqrt{N})$$

Trong đó:

- N_{list}: Số lượng cụm (clusters)
- N: Tổng số tài liệu

Cách tiếp cận này giúp tăng tốc độ truy xuất đáng kể trong khi vẫn đảm bảo độ chính xác chấp nhận được.

2.1.5. Công thức đánh giá phổ biến (IMDB Weighted Rating)

Để hạn chế sai lệch do số lượng đánh giá thấp, hệ thống sử dụng công thức trung bình có trọng số theo mô hình Bayesian:

$$W = \left(\frac{v}{v+m}\right) R + \left(\frac{m}{v+m}\right) C$$

Trong đó:

- W: Điểm đánh giá cuối cùng
- v: Số lượt đánh giá của phim
- m: Ngưỡng tối thiểu số lượt đánh giá

- R: Điểm trung bình của phim
- C: Điểm trung bình toàn bộ hệ thống

  → Công thức này giúp cân bằng giữa chất lượng và độ tin cậy của dữ liệu.

2.1.6. Cơ chế nội suy trọng số (Hybrid Blending)

Hệ thống kết hợp hai phương pháp truy hồi: khớp từ khóa (TF-IDF) và khớp ngữ nghĩa (LSA/FAISS) thông qua nội suy tuyến tính:

$$Score_{hybrid} = \alpha \cdot Score_{TFIDF} + (1 - \alpha) \cdot Score_{LSA}$$

Trong đó $alpha \in [0,1]$ là tham số điều chỉnh:

- $alpha$ lớn → ưu tiên khớp từ khóa
- $alpha$ nhỏ → ưu tiên ngữ nghĩa

  → Cơ chế này giúp hệ thống linh hoạt với nhiều dạng truy vấn khác nhau.

2.1.7. Các độ đo đánh giá trong Truy hồi thông tin (IR Metrics)

Hiệu năng hệ thống được đánh giá thông qua các chỉ số tiêu chuẩn trong lĩnh vực Information Retrieval:

Precision@K và Recall@K:

$$Precision@K = \frac{|Retrieved \cap Relevant|}{K}$$

$$Recall@K = \frac{|Retrieved \cap Relevant|}{|Relevant|}$$

Trong đó:

- K**:** Số lượng kết quả đầu tiên được xét (Top K).

- RetrievedDocs**:** Tập các kết quả hệ thống trả về.
- RelevantDocs: Tập các kết quả đúng theo Ground Truth.

→ Precision đo độ chính xác, Recall đo khả năng bao phủ kết quả đúng.

HitRate

→ Giá trị bằng 1 nếu trong Top K có ít nhất một kết quả đúng, ngược lại bằng 0.

MRR (Mean Reciprocal Rank):

$$MRR = \frac{1}{|Q|}\sum_{i=1}^{|Q|}\frac{1}{Rank_i}$$

- $|Q|$: Tổng số truy vấn kiểm thử
- Rank_i**:** Vị trí của kết quả đúng đầu tiên

→ Kết quả đúng càng xuất hiện sớm (rank nhỏ) thì MRR càng cao.

NDCG (Normalized Discounted Cumulative Gain):

$$DCG = \sum_{i=1}^{K}\frac{rel_i}{\log_2(i+1)}$$

$$NDCG = \frac{DCG}{IDCG}$$

Trong đó:

- i: Vị trí trong danh sách kết quả
- rel_i**:** Mức độ liên quan (thường là 1 hoặc 0)
- DCG: Tổng điểm sau khi áp dụng hệ số giảm theo thứ hạng

- IDCG: Giá trị DCG lý tưởng (xếp hạng hoàn hảo)

→ NDCG chuẩn hóa kết quả về khoảng $[0, 1]$, phản ánh chất lượng sắp xếp thứ hạng.

2.2. Các công trình nghiên cứu liên quan

2.2.1. Kết hợp Sparse và Dense Retrieval trong tìm kiếm chính xác cao (2023)

- Mô tả: Nghiên cứu của Gao et al. (2023) chỉ ra rằng các mô hình Dense (vector ngữ nghĩa) tuy mạnh về hiểu ngữ cảnh nhưng lại yếu trong việc xử lý các từ khóa hiếm (tên riêng, thuật ngữ đặc biệt). Ngược lại, các mô hình Sparse như TF-IDF hoặc BM25 lại xử lý rất tốt các trường hợp này.
- Liên hệ đề tài: Dựa trên nhận định này, đề tài triển khai cơ chế Hybrid Retrieval thông qua nội suy trọng số $alpha$, kết hợp điểm số từ TF-IDF và LSA nhằm tận dụng đồng thời khả năng khớp từ khóa và hiểu ngữ nghĩa, từ đó cải thiện chất lượng xếp hạng (NDCG).

2.2.2. Ứng dụng FAISS trong hệ thống gợi ý thời gian thực (2022)

- Mô tả: Nghiên cứu về FAISS cho thấy việc tính toán độ tương đồng trên tập dữ liệu lớn bằng phương pháp vét cạn (Brute-force) gây ra độ trễ cao. Giải pháp được đề xuất là sử dụng cấu trúc chỉ mục phân cụm (IVF) để giảm không gian tìm kiếm.
- Liên hệ đề tài: Đề tài áp dụng trực tiếp phương pháp này thông qua thư viện faiss.IndexIVFFlat, kết hợp chuẩn hóa L2, giúp rút gọn không gian tìm kiếm và chỉ truy xuất tập ứng viên gần nhất trong thời gian rất ngắn (mili-giây).

2.2.3. Ứng dụng LSA (Truncated SVD) trong phân tích ngữ nghĩa phim (2021)

- Mô tả: Nghiên cứu về LSA cho thấy việc sử dụng Truncated SVD để giảm chiều ma trận TF-IDF giúp loại bỏ nhiễu và làm nổi bật các "chủ đề ẩn" trong dữ liệu văn

bản.

- Liên hệ đề tài: Phương pháp này được triển khai trong hệ thống với tham số $n - components = 300$, giúp mô hình nhận diện được các mối quan hệ ngữ nghĩa (ví dụ: “funny” gần với “comedy”) thay vì chỉ phụ thuộc vào từ khóa bề mặt.

2.2.4. Tăng cường hiệu quả bằng Metadata và Feature Weighting (2024)

- Mô tả: Các nghiên cứu gần đây cho thấy văn bản dài (overview) có thể làm loãng thông tin quan trọng. Việc tăng trọng số cho các thuộc tính metadata như diễn viên, đạo diễn, thể loại giúp cải thiện đáng kể chất lượng gợi ý.
- Liên hệ đề tài: Đề tài áp dụng kỹ thuật Entity Encoding, trong đó các thành phần quan trọng được nhân trọng số (Title ×3; Genre, Director, Cast ×2), giúp mô hình ưu tiên các đặc trưng có ý nghĩa cao hơn trong quá trình truy hồi.

2.2.5. Explainable AI trong hệ thống gợi ý (2023)

- Mô tả: Theo Zhang et al. (2023), một hệ thống gợi ý hiệu quả không chỉ cần chính xác mà còn phải có khả năng giải thích kết quả nhằm tăng độ tin cậy của người dùng.
- Liên hệ đề tài: Đề tài tích hợp cơ chế Explainable AI trong giao diện, cho phép hiển thị lý do gợi ý (ví dụ: cùng diễn viên, cùng đạo diễn, tương đồng nội dung), đồng thời highlight các từ khóa liên quan, giúp người dùng hiểu rõ cơ chế hoạt động của hệ thống.

CHƯƠNG 3. THIẾT KẾ TRIỂN KHAI HỆ THỐNG

3.1. Tổng quan phương pháp hiện thực

Hệ thống truy hồi và gợi ý phim được xây dựng dựa trên sự kết hợp giữa các kỹ thuật Xử lý Ngôn ngữ Tự nhiên (NLP) và Truy hồi Thông tin (Information Retrieval – IR). Thay vì sử dụng các phương pháp tìm kiếm truyền thống dựa trên cơ sở dữ liệu quan hệ (SQL) hoặc so khớp từ khóa đơn thuần, hệ thống áp dụng triết lý Tìm kiếm Lai (Hybrid Search) kết hợp với Lọc theo nội dung (Content-Based Filtering) nhằm nâng cao độ chính xác và khả năng hiểu ngữ nghĩa của truy vấn.

Phương pháp hiện thực của hệ thống được xây dựng dựa trên các tiêu chí cốt lõi sau:

3.1.1. Phương pháp xử lý dữ liệu hướng thực thể (Entity-Centric Data Engineering)

Dữ liệu phim ban đầu tồn tại dưới nhiều nguồn khác nhau (MovieLens, TMDB) với các định dạng không đồng nhất (CSV, JSON) và bị phân mảnh theo nhiều bảng. Hệ thống thực hiện quá trình hợp nhất dữ liệu (Data Merging) dựa trên khóa liên kết tmdbId để tạo thành một tập dữ liệu thống nhất.

Bên cạnh đó, thay vì sử dụng trực tiếp văn bản mô tả dài (overview), hệ thống áp dụng kỹ thuật "Đóng gói thực thể" (Entity Encoding). Cụ thể, các trường thông tin quan trọng như:

- Tiêu đề phim (Title)
- Đạo diễn (Director)
- Diễn viên (Cast)
- Thể loại (Genres)

được nhân trọng số bằng cách lặp lại trong văn bản đầu vào (ví dụ: Title ×3, Cast/Director ×2). Điều này giúp mô hình học máy tập trung mạnh hơn vào các đặc trưng quan trọng, tránh bị "nhiễu" bởi nội dung mô tả dài và không đồng đều.

3.1.2. Phương pháp truy hồi thông tin lai (Hybrid Retrieval Approach)

Để khắc phục hạn chế của từng phương pháp riêng lẻ, hệ thống áp dụng mô hình truy hồi lai bằng cách kết hợp hai hướng tiếp cận:

- Nhánh truy hồi bề mặt (Lexical Matching): Sử dụng mô hình TF-IDF kết hợp N-gram (1,2) để xử lý các truy vấn mang tính từ khóa, đặc biệt hiệu quả với tên riêng, thuật ngữ hiếm hoặc cụm từ cố định.
- Nhánh truy hồi ngữ nghĩa (Semantic Matching): Áp dụng Truncated SVD (LSA) để giảm chiều không gian TF-IDF xuống khoảng 300 chiều, qua đó trích xuất các "chủ đề tiềm ẩn". Các vector này được đưa vào hệ thống FAISS (Facebook AI Similarity Search) để thực hiện tìm kiếm lân cận gần nhất (Approximate Nearest Neighbor – ANN) với độ trễ thấp.

Điểm số của hai nhánh được kết hợp thông qua hệ số nội suy tuyến tính α:

$$Score_{hybrid} = \alpha \cdot Score_{TFIDF} + (1 - \alpha) \cdot Score_{LSA}$$

Hệ số α có thể được điều chỉnh trực tiếp trên giao diện, cho phép cân bằng giữa độ chính xác từ khóa và khả năng hiểu ngữ nghĩa.

3.1.3. Phương pháp tái xếp hạng và heuristic (Re-ranking & Heuristics)

Kết quả truy hồi từ không gian vector thường chỉ phản ánh mức độ tương đồng nội dung, nhưng chưa xét đến yếu tố thực tế như mức độ yêu thích của người dùng. Do đó, hệ thống áp dụng bước **tái xếp hạng (Re-ranking)** bằng cách tích hợp thêm các đặc trưng:

- Điểm đánh giá trung bình (Average Rating)
- Số lượng đánh giá (Number of Ratings)
- Điểm phổ biến (Bayesian Popularity Score)

Các yếu tố này được chuẩn hóa và kết hợp vào điểm cuối cùng (**hybrid_score**) nhằm cải thiện chất lượng kết quả.

Ngoài ra, trong module gợi ý phim, hệ thống còn áp dụng các **luật heuristic (rule-based)** để tăng độ chính xác, bao gồm:

- Thưởng điểm cho phim cùng series (Sequel/Collection)
- Thưởng điểm cho phim cùng đạo diễn
- Thưởng điểm cho phim có diễn viên trùng lặp

Các quy tắc này giúp mô hình phản ánh tốt hơn hành vi và sở thích thực tế của người dùng.

3.1.4. Khung kiến trúc ứng dụng (Application Framework)

Hệ thống được thiết kế theo mô hình phân tầng rõ ràng giữa:

- **Backend:**
  Xử lý dữ liệu, xây dựng mô hình và lưu trữ dưới dạng các file tuần tự hóa (.pkl), bao gồm TF-IDF Matrix, LSA Matrix và FAISS Index.
- **Frontend:**
  Giao diện người dùng được xây dựng bằng framework **Streamlit**, cho phép tương tác trực tiếp với hệ thống tìm kiếm và gợi ý.

Các mô hình được nạp sẵn vào bộ nhớ (RAM) thông qua cơ chế cache, giúp giảm thiểu thời gian truy xuất và đạt được **độ trễ gần thời gian thực (near real-time)** trong quá trình tìm kiếm.

3.2. Mô tả hệ thống (System Overview)

Hệ thống được thiết kế theo kiến trúc Phân hệ (Modular Architecture), phân tách rõ rệt giữa tầng xử lý dữ liệu vật lý (Data Pipeline), mô hình học máy (Core Engines) và giao diện trực quan (UI). Toàn bộ mã nguồn hoạt động theo một quy trình nối tiếp khép kín.

3.2.1. Pipeline tổng thể:

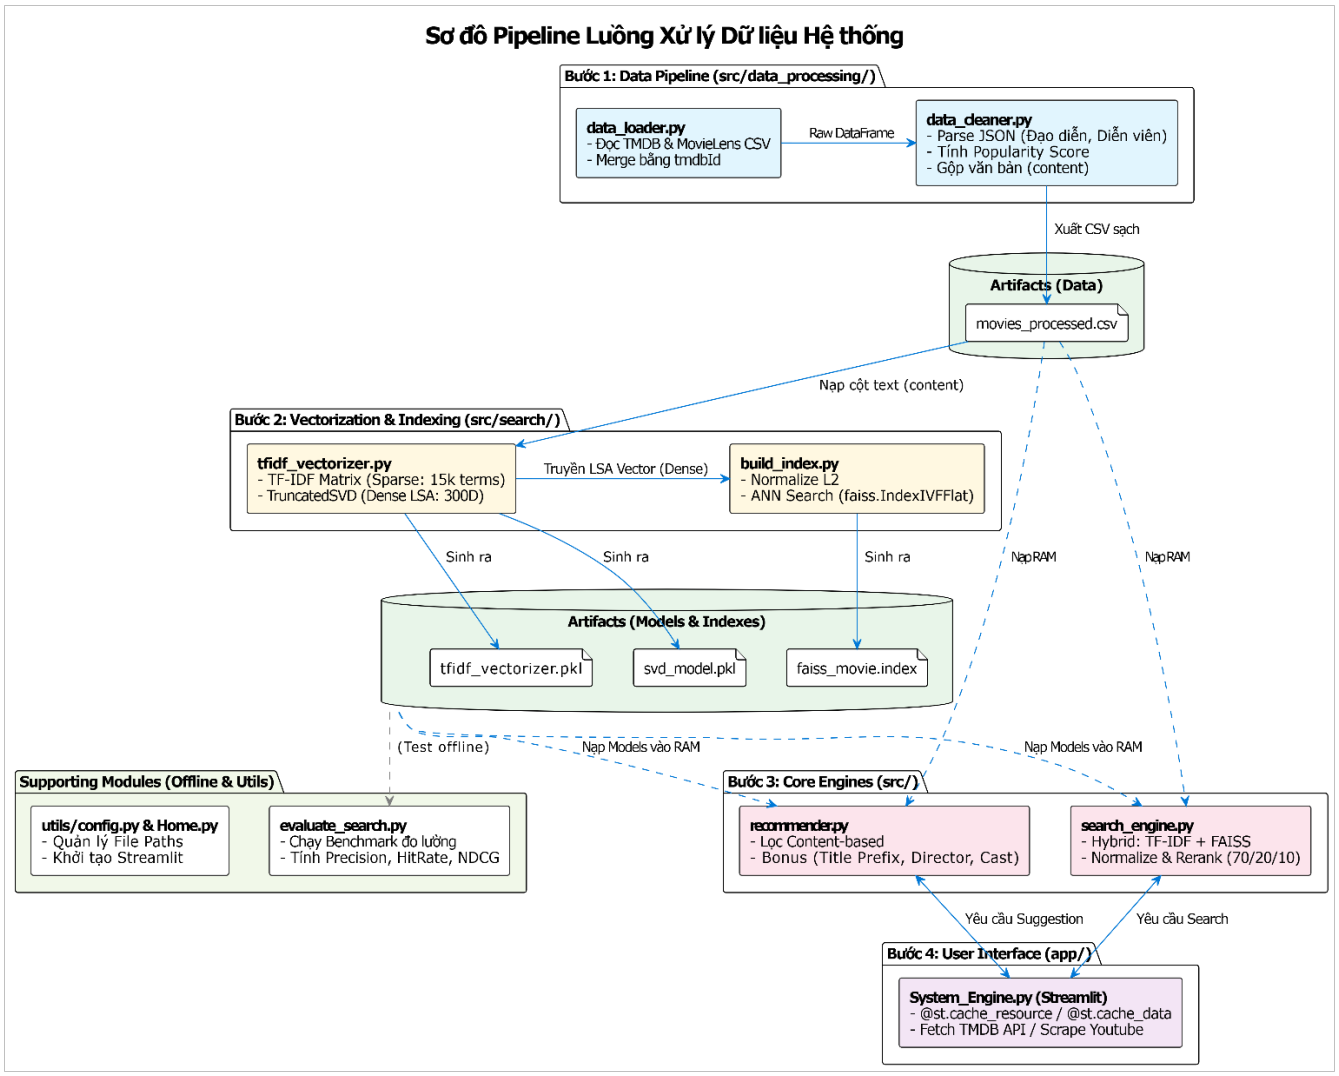

Hình 1. Sơ đồ Pipeline Luồng Xử lý Dữ liệu

3.2.2. Mô tả từng module

Hệ thống được chia thành 5 phân hệ rõ ràng. Mỗi phân hệ đảm nhận một nhiệm vụ chuyên biệt được phân tách hoàn toàn (decoupled).

1. Phân hệ Tiền xử lý dữ liệu (src/data_processing/)

- Chức năng: Thực thi quy trình Trích xuất, Biến đổi và Nạp dữ liệu (ETL).
- Chi tiết mã nguồn:
  - data_loader.py: Đọc các tệp CSV thô, thực hiện lệnh merge dựa trên khóa ngoại tmdbId để hợp nhất điểm số của MovieLens với thông tin metadata của TMDB.
  - data_cleaner.py: Xử lý ngoại lệ, trích xuất chuỗi JSON (danh sách Đạo diễn, Diễn viên). Tính toán điểm phổ biến (popularity_score) theo công thức Bayes và đúc kết thành một cột văn bản gộp duy nhất mang tên content (đã được đánh trọng số thực thể bằng cách nhân 3 lần chuỗi Title). Cuối cùng xuất ra file movies_processed.csv.

2. Phân hệ Khởi tạo Vector và Chỉ mục (src/search/)

- Chức năng: Xây dựng không gian toán học biểu diễn văn bản.
- Chi tiết mã nguồn:
  - tfidf_vectorizer.py: Khởi tạo TfidfVectorizer sinh ra ma trận biểu diễn thưa (Sparse matrix) với 15,000 từ vựng. Sau đó dùng thuật toán TruncatedSVD giảm chiều ma trận này thành các không gian biểu diễn ngữ nghĩa cô đặc (Dense LSA matrix 300D) và lưu trữ dưới dạng các file .pkl.
  - build_index.py: FAISS sử dụng cấu trúc IndexIVFFlat để phân hoạch không gian vector 300D thành các cụm Voronoi sau khi đã chuẩn hóa L2 (faiss.normalize_L2). Việc này cho phép hệ thống truy vấn gần đúng (Approximate Nearest Neighbor – ANN) với độ trễ siêu việt.

3. Phân hệ Động cơ cốt lõi (Core Engines)

- Chức năng: Trái tim của ứng dụng, tiếp nhận lệnh và ra quyết định kết quả.
- Chi tiết mã nguồn:
  - search_engine.py: Chứa class MovieSearchEngine. Thuật toán sẽ chia tỷ lệ (pha trộn) điểm đa chiều qua trọng số α. Trước khi gộp điểm, hệ thống thực hiện phép Chuẩn hóa (Normalization) ép toàn bộ tập điểm về khoảng [0,1]. Điểm phân hạng

cuối cùng (hybrid_score) được nội suy chặt chẽ theo tỷ lệ: 70 %gốc tương đồng văn bản, 20% chất lượng đánh giá và 10% sức hút phổ biến.

- recommender.py: Chứa class MovieRecommender. Chịu trách nhiệm tìm phim tương đồng nhưng tích hợp thêm bộ luật nâng cao (Heuristic bonus) cực mạnh bao gồm: (1) So khớp tiền tố tiêu đề (Prefix matching) để phát hiện Sequel/Series; (2) Thưởng điểm nóng nếu trùng Đạo diễn; và (3) Tính điểm dâng bậc dựa trên độ chồng lặp (Overlap) về số lượng Diễn viên chung.

4. Phân hệ Giao diện người dùng (app/ & gốc)

- Chức năng: Điểm tiếp xúc trực quan (Client-side) với người dùng ở thời gian thực.
- Chi tiết mã nguồn:
  - System_Engine.py, Home.py: Xây dựng trên nền tảng Streamlit. Nòng cốt của file này là việc sử dụng decorator @st.cache_resource và @st.cache_data. Cơ chế caching này trói chặt toàn bộ 15.000 điểm mảng Vector nặng nề trong bộ nhớ phần cứng (RAM), ngăn chặn việc reload lại từ đầu mỗi khi người dùng ấn nút tìm kiếm, giúp kéo độ trễ (latency) về tiệm cận thời gian thực. Giao diện tích hợp quét Regex nguồn phát của Youtube (Trailer) và kết nối API của hãng TheMovieDatabase.

5. Phân hệ Phụ trợ và Đánh giá (Offline Utils)

- Chức năng: Thiết lập môi trường và đo lường kiểm thử.
- Chi tiết mã nguồn:
  - evaluate_search.py: Chạy ngầm Offline trên Console, đo lường toàn diện hiệu suất mô hình qua Ground truths thực tế và cho ra các chỉ số Precision, HitRate, MRR, NDCG phục vụ cho Chương báo cáo Thực nghiệm.
  - utils/config.py: Quản lý tập trung các đường dẫn môi trường tuyệt đối (Absolute paths), đảm bảo code được biên dịch không lỗi "Path not found" thông qua cơ chế os.path.dirname.

3.3. Công cụ hiện thực

Quá trình phát triển và triển khai hệ thống được bảo đảm bởi hệ sinh thái công nghệ mã nguồn mở, cấu hình tối ưu cho bài toán Khoa học Dữ liệu và Xử lý Ngôn ngữ Tự nhiên (NLP). Chi tiết các công cụ được tổng hợp trong bảng sau:

Table 1. Các công cụ và thư viện cấu thành hệ thống

STT	Phân lớp Công nghệ	Tên Công cụ / Thư viện	Mục đích áp dụng trong Hệ thống
1	Ngôn ngữ lõi	Python 3.x	Nền tảng lập trình cốt lõi, cung cấp cú pháp linh hoạt và hệ sinh thái thư viện mạnh mẽ cho mô hình hóa AI.
2	Tiền xử lý Dữ liệu	pandas, numpy, re	Phân tích và thao tác định dạng DataFrame; làm sạch văn bản bằng RegEx; xử lý và hợp nhất dữ liệu khuyết thiếu.
3	Khai phá Đặc trưng	scikit-learn (TfidfVectorizer, TruncatedSVD)	Thực thi thuật toán Machine Learning cổ điển: Trích xuất ma trận thưa TF-IDF (10,000 chiều) và nén không gian LSA (300 chiều).
4	Truy hồi Không gian	faiss-cpu (Facebook Research)	Xây dựng cấu trúc chỉ mục Inverted Index; đối sánh vector không gian bằng thuật toán tìm kiếm lân cận gần nhất (KNN) ở tốc độ cao.
5	Giao diện & Ứng dụng	streamlit	Khởi tạo giao diện Web phi trạng thái (Stateless); quản lý Session nội bộ để duy trì biến tương tác của người dùng.
6	Tích hợp Ngoại vi	API urllib.request, json	Giao tiếp Asynchronous HTTP lấy dữ liệu Poster từ TMDB và cào (crawl)

			Video Trailer từ hệ thống YouTube.
7	Lưu trữ Mô hình	pickle	Tuần tự hóa (Serialization) các ma trận vector và mô hình học máy thành tệp nhị phân để nạp nhanh vào bộ nhớ RAM.

3.4. Tập dữ liệu

3.4.1. Nguồn gốc và Thu thập dữ liệu (Data Sources & Collection)

Để đảm bảo hệ thống có độ bao phủ tri thức rộng và thông tin có tính xác thực cao, kho ngữ liệu (Corpus) của đồ án được cấu thành từ việc dung hợp (merge) hai bộ cơ sở dữ liệu mở phổ biến nhất trong miền điện ảnh:

1. The Movies Dataset (Kaggle/TMDB): Cung cấp hệ thống siêu dữ liệu (Metadata) khổng lồ bao gồm: Tóm tắt cốt truyện (Overview), Danh sách Tín dụng (Credits: Đạo diễn, Diễn viên), và Mã định danh kết nối API (TMDB ID).
2. MovieLens Dataset (GroupLens Research): Đóng vai trò cung cấp ma trận tương tác của người dùng, bao gồm số lượng đánh giá (Num Ratings) và Điểm số trung bình (Average Rating). Dữ liệu này là cơ sở Toán học bắt buộc cho thuật toán Reranking (Xếp hạng lại) của hệ thống.

3.4.2. Giai đoạn tiền xử lý thống kê và gộp dữ liệu (Data Aggregation & Merging)

Do cấu trúc của bộ dữ liệu gốc (Raw Data) được thiết kế theo lược đồ chuẩn hóa (Normalized Schema) phân tán trên nhiều tệp tin độc lập, hệ thống cần thực thi quá trình tích hợp dữ liệu (Data Integration) để tạo ra một không gian làm việc thống nhất. Quá trình này được đảm nhiệm bởi module data_loader.py.

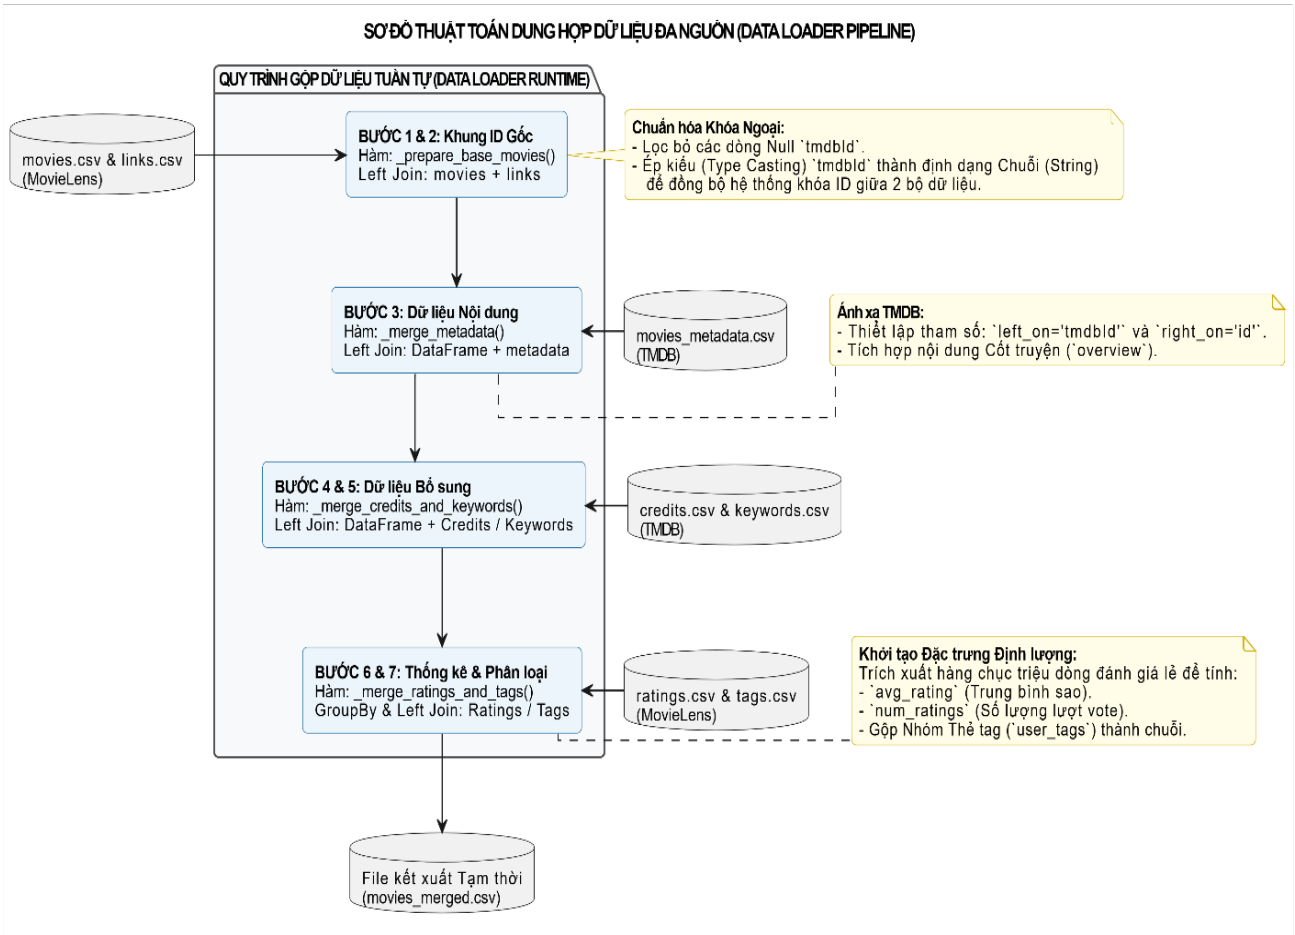

Hình 2. Sơ đồ luồng thuật toán hợp nhất tập dữ liệu MovieLens và TMDB.

Giải thích sơ đồ:

Bước 1 & 2: Khởi tạo Lược đồ lõi và Chuẩn hóa Khóa ngoại (_prepare_base_movies)

- Hệ thống lấy file movies.csv làm gốc và thực hiện phép kết nối với links.csv.
- Xử lý xung đột cơ sở dữ liệu: Tại bước này, thuật toán lọc bỏ các bản ghi không tồn tại mã liên kết (NaN tmdbId). Sau đó tiến hành Ép kiểu (Type Casting) trường tmdbId từ dạng nguyên (Integer) sang dạng chuỗi (String). Kỹ thuật này là bắt buộc để đồng bộ hệ thống khóa (Key) giữa Pandas và siêu dữ liệu của TMDB, tránh lỗi Type Mismatch khi nối bảng.

Bước 3: Tích hợp Siêu dữ liệu TMDB (_merge_metadata)

- Hệ thống tiến hành đối sánh Dataframe hiện tại với movies_metadata.csv.
- Thao tác kỹ thuật: Khai báo tham số left_on='tmdbId' và right_on='id'. Việc này cho phép thuật toán kéo thành công các trường quan trọng như Lược truyện (overview), ngôn ngữ gốc và ngày phát hành vào khung dữ liệu lõi.

Bước 4 & 5: Bổ sung Dữ liệu Thực thể (_merge_credits_and_keywords)

- Tiếp tục gộp tệp credits.csv và keywords.csv để lấy mảng JSON chứa danh sách Đạo diễn, Diễn viên và Từ khóa cốt lõi.
- Thao tác kỹ thuật: Trong quá trình nối, thuật toán lập trình bổ sung hàm df.loc[:, ~df.columns.duplicated()] để tự động dọn dẹp các cột id rác bị Pandas phát sinh lặp lại (duplicate) trong quá trình Left Join, giữ cho cấu trúc bảng luôn gọn nhẹ.

Bước 6 & 7: Tiền xử lý Thống kê Định lượng (_merge_ratings_and_tags)

- Thay vì nối trực tiếp, hệ thống phải xử lý trước lượng dữ liệu khổng lồ từ ratings.csv (chứa hàng triệu tương tác của người dùng).
- Thao tác kỹ thuật: Sử dụng thuật toán GroupBy trên thuộc tính movieId, gọi hàm nội suy .agg() để tính toán hai chỉ số trọng yếu: avg_rating (Trung bình số sao bầu chọn) và num_ratings (Tổng lượng người dùng đã biểu quyết). Đây là căn cứ Toán học vững chắc để phục vụ cho cơ chế xếp hạng (Reranking) bù trừ của Mạng Lai (Hybrid) ở chặng sau.

3.4.3. Giai đoạn chuẩn hóa, Làm sạch và Sinh Đặc trưng (Data Cleaning & Feature Engineering)

Nếu như Giai đoạn 1 đóng vai trò gom nhóm dữ liệu, thì Giai đoạn 2 (đảm nhiệm bởi module data_cleaner.py) là trái tim của hệ thống Tiền xử lý. Các mô hình học máy (LSA, TF-IDF) đặc biệt nhạy cảm với dữ liệu nhiễu, do đó một pipeline làm sạch sâu bao gồm 6 bước đã được thiết lập để bóc tách, mã hóa và sinh các đặc trưng lõi.

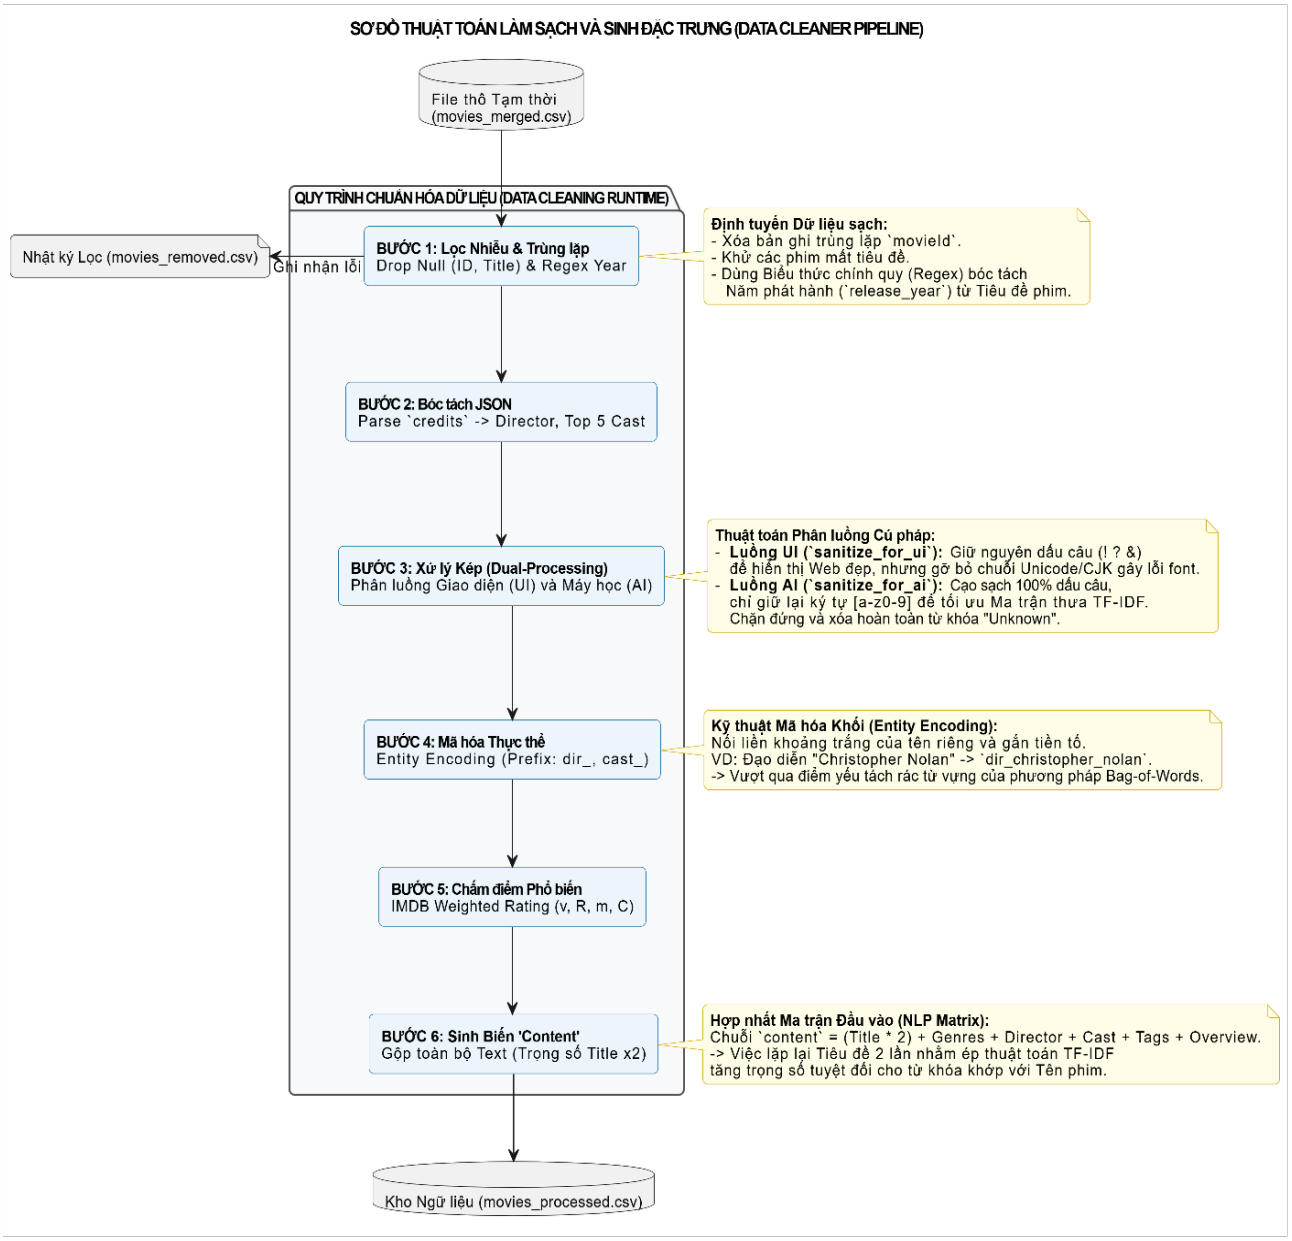

Hình 3. Sơ đồ quá trình làm sạch, chuẩn hóa và sinh đặc trưng văn bản

Giải thích sơ đồ:

Bước 1: Lọc Nhiễu và Trùng lặp (Data Purging & Extraction)

- Thao tác: Khử các bản ghi trùng lặp ID, xóa bỏ các bộ phim không có tiêu đề hợp lệ, đồng thời sử dụng Biểu thức chính quy (Regex) để trích xuất mốc thời gian (release_year) ẩn bên trong chuỗi tiêu đề.
- Mục đích: Đảm bảo tính toàn vẹn (Integrity) của dữ liệu. Nếu để lọt các bản ghi rỗng (Null/NaN) vào hàm sinh ma trận, thuật toán của Scikit-learn sẽ lập tức báo lỗi

(Exception) và dừng hệ thống. Các bản ghi lỗi này không bị xóa vĩnh viễn mà được chuyển tham chiếu lưu trữ vào movies_removed.csv để phục vụ công tác Debug.

Bước 2: Giải mã Khối JSON (JSON Parsing)

- Thao tác: Chuyển đổi định dạng chuỗi JSON nguyên bản của hai cột cast và crew thành các mảng danh sách định danh (chỉ lấy Đạo diễn và Top 5 Diễn viên chính).
- Mục đích: Dữ liệu thô chứa quá nhiều thông tin không cần thiết (người trang điểm, ánh sáng, diễn viên quần chúng). Việc bóc tách hạt nhân cốt lõi giúp hệ thống giảm thiểu chiều không gian ma trận (Dimensionality Reduction) và tiết kiệm bộ nhớ RAM khi huấn luyện.

Bước 3: Cơ chế Xử lý Kép (Dual-Processing Strategy)

- Thao tác: Khởi tạo hai hàm làm sạch độc lập. sanitize_for_ui giữ nguyên dấu câu (phục vụ hiển thị Web). sanitize_for_ai làm sạch 100% dấu câu, đưa về chữ thường và chặn đứng các chuỗi nội dung mang tên "Unknown".
- Mục đích: Hệ thống giải quyết trọn vẹn "Nghịch lý Dữ liệu". Người dùng cần xem văn bản có dấu câu chuẩn chỉ, nhưng Mô hình AI (TF-IDF) lại bị nhiễu bởi dấu câu. Đặc biệt, nếu không chặn từ "Unknown" (vốn xuất hiện rất nhiều khi dữ liệu bị khuyết), từ khóa này sẽ trở thành một Đặc trưng thống trị (Dominant Feature), khiến AI gợi ý các bộ phim không liên quan chỉ vì chúng... cùng bị thiếu dữ liệu.

Bước 4: Kỹ thuật Mã hóa Thực thể (Entity Encoding)

- Thao tác: Gắn tiền tố và nối liền các khoảng trắng của danh từ riêng. Ví dụ: Christopher Nolan được mã hóa cứng thành token dir_christopher_nolan.
- Mục đích: Khắc phục điểm yếu chí mạng của mô hình Bag-of-Words (BoW). Mô hình ngôn ngữ thông thường sẽ băm chuỗi thành hai từ độc lập là "Christopher" và "Nolan". Điều này khiến thuật toán nhầm lẫn giữa Đạo diễn Christopher và một nhân vật có tên Christopher trong cốt truyện. Kỹ thuật Entity Encoding ép máy học

phải nhìn nhận đây là một "siêu từ vựng" duy nhất.

Bước 5: Chấm điểm Phân hạng Bù trừ (IMDB Weighted Rating)

- Thao tác: Tính toán biến popularity_score dựa trên Bayesian Average (với các tham số lượng vte v, điểm số R, mốc vote tối thiểu m, trung bình toàn cục C).
- Mục đích: Điểm Rate trung bình thô rất thiếu khách quan. Một bộ phim rác có 1 người chấm 5 sao không thể xếp trên một Siêu phẩm có 10,000 người chấm 4.8 sao. Công thức chuẩn IMDB này sẽ trừng phạt (Penalize) hoặc thưởng (Reward) điểm dựa vào độ uy tín của số lượt Vote, cung cấp một hệ số Xếp hạng lại (Reranking) cực kỳ chính xác cho Search Engine.

Bước 6: Hợp nhất Ma trận Đầu vào (Content Matrix Generation)

- Thao tác: Gom toàn bộ biến văn bản vào một trường content duy nhất. Đặc biệt, trường Tiêu đề (Title) được cộng nhân đôi vào chuỗi.
- Mục đích: Vì hệ thống sử dụng chung một đầu vào cho cả truy vấn Nội dung và truy vấn Tên phim. Bằng cách lặp lại Tên phim 2 lần trong chuỗi content, ta đánh lừa thuật toán TF-IDF (Tần suất Từ khóa), ép độ ưu tiên tuyệt đối cho Tên phim. Nếu người dùng gõ từ "Batman", các bộ phim có tên Batman sẽ lập tức trồi lên trên các bộ phim chỉ có nội dung nhắc đến Batman.

3.5. Mô hình truy hồi

Mô hình truy hồi đóng vai trò là "bộ não" của hệ thống, chịu trách nhiệm tiếp nhận câu truy vấn ngôn ngữ tự nhiên (Natural Language Query) từ người dùng và tính toán trả về danh sách Top-K các bộ phim phù hợp nhất. Nhận thức được giới hạn của các công cụ tìm kiếm truyền thống, hệ thống được thiết kế theo cấu trúc Truy hồi Lai (Hybrid Search Engine), kết hợp giữa Bắt khớp Cú pháp (Lexical Matching) và Khám phá Ngữ nghĩa (Semantic Searching).

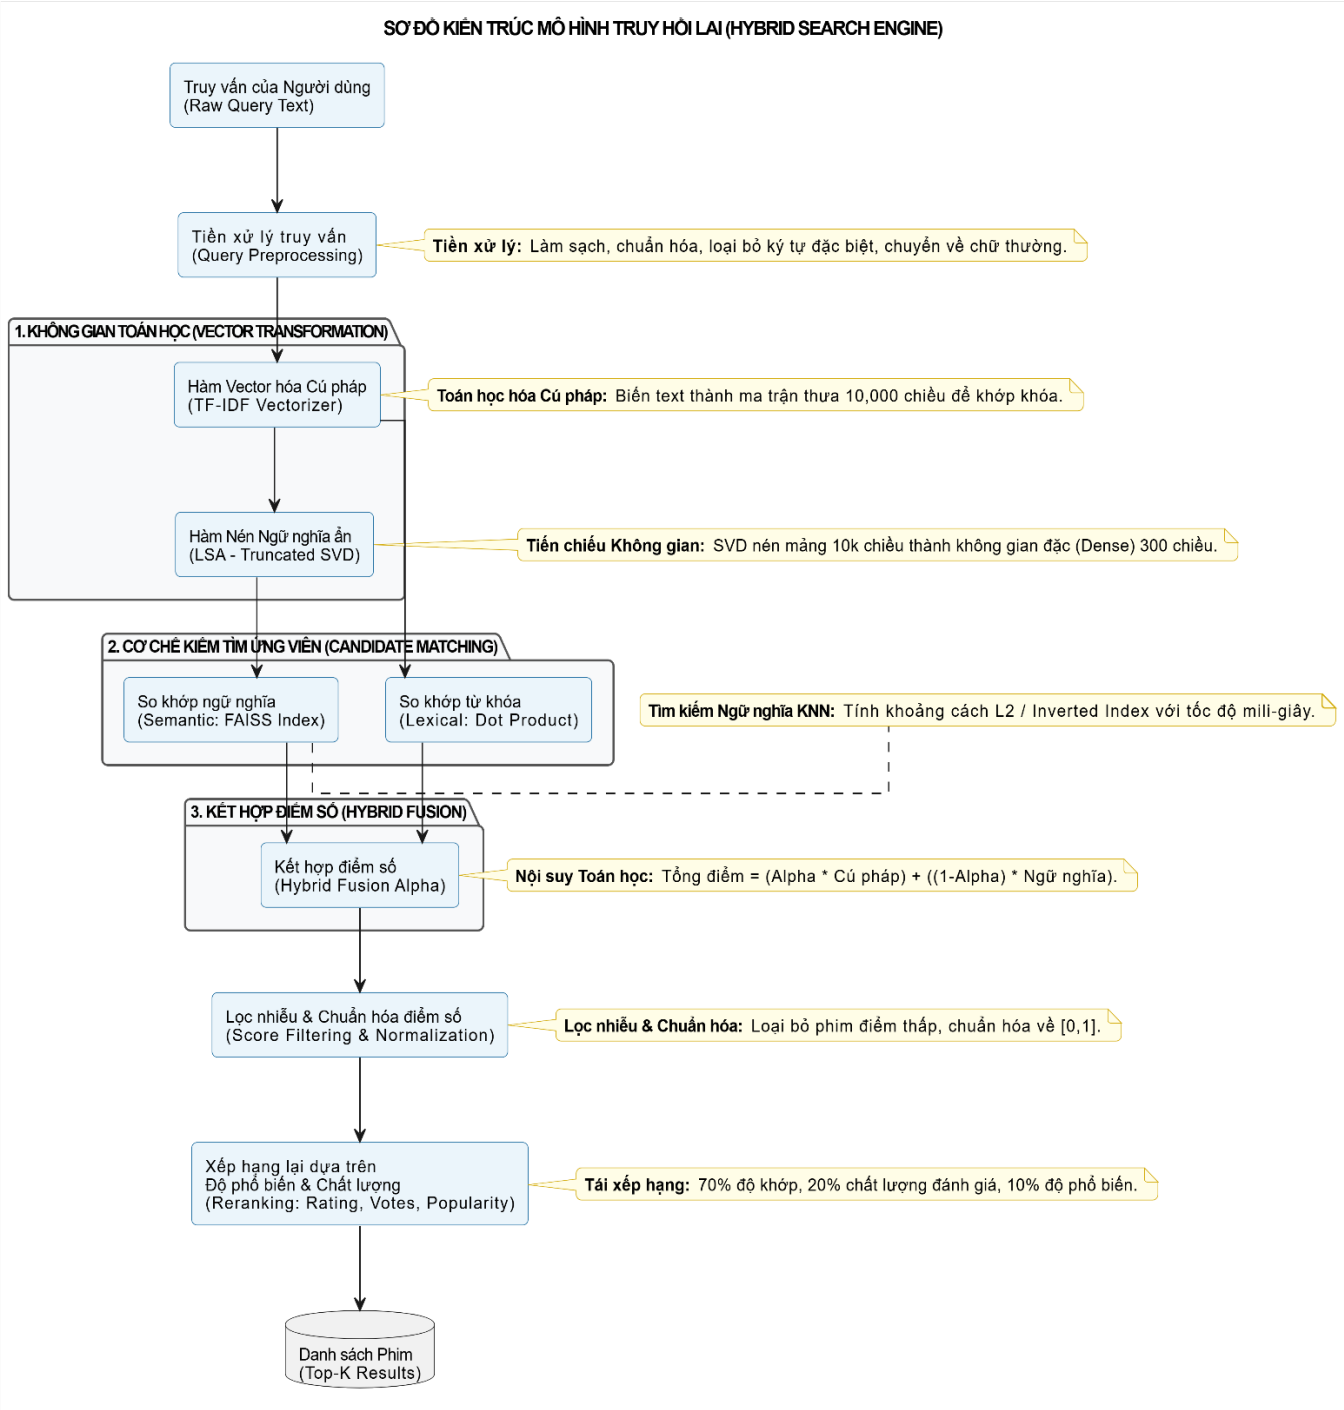

Hình 4. Sơ đồ kiến trúc mô hình truy hồi lai

Giải thích sơ đồ:

Bước 1: Tiền xử lý truy vấn (Query Preprocessing)

- Khi người dùng nhập một câu truy vấn (ví dụ: tên phim, mô tả nội dung, tên diễn viên), hệ thống sẽ làm sạch văn bản này. Cụ thể, hệ thống loại bỏ các ký tự đặc biệt,

chuyển toàn bộ về chữ thường, và chuẩn hóa lại chuỗi để đảm bảo không có lỗi chính tả hoặc ký tự lạ gây nhiễu cho mô hình.

- Mục đích của bước này là để mọi truy vấn đều ở dạng chuẩn, giúp các thuật toán phía sau hoạt động chính xác và ổn định.

Bước 2: Biến đổi truy vấn thành vector (Vector Transformation)

- Sau khi làm sạch, truy vấn được chuyển thành hai dạng vector:
- Vector TF-IDF: Đây là một vector rất lớn (khoảng 10.000 chiều), mỗi chiều đại diện cho một từ hoặc cụm từ trong toàn bộ kho phim. Vector này giúp hệ thống nhận diện chính xác các từ khóa quan trọng, đặc biệt là tên riêng, tên phim, đạo diễn, diễn viên.
- Vector LSA (SVD): Vector TF-IDF sau đó được nén lại thành một vector nhỏ hơn (300 chiều) bằng kỹ thuật SVD. Vector này giúp hệ thống hiểu được ý nghĩa ngữ cảnh, từ đồng nghĩa, và các mối liên hệ sâu hơn giữa các bộ phim.

Bước 3: Tìm kiếm ứng viên phù hợp (Candidate Matching)

- Hệ thống sẽ đồng thời thực hiện hai phép so khớp:
- So khớp từ khóa (Lexical Matching): So sánh trực tiếp vector TF-IDF của truy vấn với toàn bộ vector TF-IDF của các phim trong kho dữ liệu. Cách này giúp tìm ra các phim có chứa từ khóa giống hoặc gần giống với truy vấn.
- So khớp ngữ nghĩa (Semantic Matching): So sánh vector LSA của truy vấn với vector LSA của các phim bằng thuật toán FAISS. Cách này giúp tìm ra các phim có ý nghĩa, chủ đề hoặc ngữ cảnh gần giống với truy vấn, kể cả khi không trùng từ khóa.

Bước 4: Kết hợp điểm số (Hybrid Fusion)

- Hai loại điểm số từ bước trên sẽ được kết hợp lại bằng một công thức nội suy, sử dụng tham số alpha (α). Alpha cho phép điều chỉnh tỷ lệ ưu tiên giữa điểm từ khóa và điểm ngữ nghĩa. Ví dụ, nếu alpha = 0.7 thì hệ thống sẽ ưu tiên 70% cho điểm từ

khóa và 30% cho điểm ngữ nghĩa.

- Việc này giúp hệ thống vừa đảm bảo tìm đúng phim theo từ khóa, vừa không bỏ sót các phim có nội dung liên quan nhưng dùng từ khác.

Bước 5: Lọc nhiễu và chuẩn hóa điểm số

- Hệ thống sẽ loại bỏ các phim có điểm số tổng hợp quá thấp (dưới một ngưỡng nhất định, ví dụ 0.05) để tránh trả về các phim không liên quan.
- Tất cả các điểm số còn lại sẽ được chuẩn hóa về cùng một thang điểm (từ 0 đến 1) để đảm bảo công bằng khi so sánh.

Bước 6: Tái xếp hạng dựa trên độ phổ biến và chất lượng (Reranking)

- Sau khi có danh sách các phim phù hợp, hệ thống sẽ tính thêm điểm uy tín cho từng phim dựa trên số lượng người đánh giá, điểm trung bình đánh giá và độ phổ biến (popularity score).
- Công thức tính điểm cuối cùng sẽ ưu tiên:
  - 70% cho độ khớp nội dung (từ khóa + ngữ nghĩa)
  - 20% cho chất lượng đánh giá (rating, số lượng vote)
  - 10% cho độ phổ biến (popularity)
- Nhờ đó, các phim nổi tiếng, được nhiều người đánh giá cao sẽ được ưu tiên xuất hiện ở đầu danh sách, còn các phim ít người biết hoặc chất lượng thấp sẽ bị đẩy xuống dưới.

Bước 7: Trả về kết quả cho người dùng

- Cuối cùng, hệ thống sẽ trả về danh sách Top-K phim phù hợp nhất với truy vấn của người dùng, đảm bảo vừa đúng chủ đề, vừa chất lượng, vừa phổ biến.

CHƯƠNG 4. THỰC NGHIỆM

4.1. Mô tả dataset

Tập dữ liệu nền tảng được sử dụng để tiến hành hệ thống hóa không gian vector và chạy kịch bản đánh giá là tập tin movies_processed.csv. Quá trình kiểm thử cho thấy, từ 9.734 bản ghi thô ban đầu thu thập được từ nguồn MovieLens và TMDB, mô hình Tiền xử lý (Data Cleaner) đã tự động thanh lọc các dòng dữ liệu khuyết thiếu (Missing ID, Missing Title) và các tiêu đề bất hợp quy.

Kết quả, kho ngữ liệu cuối cùng bảo toàn được chính xác 9.514 bản ghi (đạt tỷ lệ giữ vẹn ~97.7%). Mỗi bản ghi cấu thành từ 14 trường thuộc tính độc lập, được thiết kế chuyên biệt để phục vụ hai mục tiêu song song: Hiển thị trực quan trên Giao diện Web (UI) và tính toán khoảng cách trong Không gian Vector (AI/NLP).

4.1.1. Từ điển dữ liệu (Data Dictionary)

Cấu trúc lược đồ (Schema) của tập dữ liệu thực nghiệm được chia làm 3 nhóm chức năng chính: Nhóm Định danh, Nhóm Đặc trưng truy hồi (AI), và Nhóm Giao diện (UI). Chi tiết được trình bày trong bảng sau:

Table 2. Bảng các thuộc tính của dataset *movies_processed.csv*

STT	Tên thuộc tính (Column)	Kiểu dữ liệu	Nhóm chức năng	Diễn giải ý nghĩa (Description)
1	movieId	Integer	Định danh	Khóa chính (Primary Key) nội bộ dùng để đối xứng vị trí véc-tơ.
2	tmdbId	Integer	Định danh	Khóa ngoại dùng để truy xuất hình ảnh Poster và Video Trailer từ API.
3	title_clean	String	AI & UI	Tiêu đề phim đã khử ký tự đặc biệt, hiển thị và phục vụ tìm kiếm.

4	release_year	Integer	Phân loại	Năm phát hành (Dùng để lọc và nâng cao gợi ý).
5	director	String	UI	Tên đạo diễn gốc hiển thị trên Web (VD: Christopher Nolan).
6	cast_str	String	UI	Top 5 diễn viên gốc hiển thị trên Web (VD: Leonardo DiCaprio,...).
7	genres_str	String	UI	Thể loại phim nguyên bản phân cách bằng dấu phẩy.
8	avg_rating	Float	AI (Gốc)	Điểm số trung bình người dùng đánh giá (Thang 1-5).
9	num_ratings	Integer	AI (Gốc)	Khối lượng tham gia Vote của cộng đồng.
10	popularity_score	Float	AI (Rerank)	Trọng số IMDB thuật toán tự nội suy, dùng để phạt/thưởng khi xếp hạng.
11	overview	String	UI	Nội dung tóm tắt hiển thị trực quan, còn giữ nguyên dấu câu.
12	poster_path	String	UI	Đường dẫn đuôi định danh để Fetch ảnh từ máy chủ.
13	runtime	Integer	UI	Thời lượng bộ phim (Phút).
14	content	String	AI (Vector)	Trường đặc trưng lõi: Chuỗi gộp siêu cấp đã cạo sạch dấu câu, gắn mã Entity và nhân đôi trọng số Tiêu đề phục vụ TF-IDF.

4.1.2. Bảng dữ liệu mẫu (Data Representation Sample)

Để kiểm chứng tính toàn vẹn của thuật toán Tiền xử lý, dưới đây là một lát cắt minh họa (Data Slice) cho một bản ghi cụ thể trước khi được máy học nạp vào bộ nhớ RAM. Lát cắt này tập trung thể hiện sự khác biệt giữa văn bản hiển thị và văn bản nhúng.

Table 3. Bảng dữ liệu mẫu của tập dataset *movies_processed.csv*

Thuộc tính quan trọng	**Giá trị trích xuất thực tế (Mô phỏng 1 bộ phim Bomb tấn)**
title_clean	Inception
release_year	2010
popularity_score	4.152 (Vượt trội nhờ lượng người vote khủng)
director	Christopher Nolan
cast_str	Leonardo DiCaprio, Joseph Gordon-Levitt, Elliot Page
overview	Cobb, a skilled thief who commits corporate espionage by infiltrating the subconscious of his targets...
content (Dữ liệu ép vào AI)	inception inception action science fiction adventure dir_christopher_nolan cast_leonardo_dicaprio cast_joseph_gordon_levitt cast_elliot_page dream thief subconscious espionage target...

Nhận xét: Bảng trên chứng minh rõ nét hiệu quả của phương pháp "Dual-Processing" (Xử lý kép) trong đồ án. Người dùng vẫn đọc được Overview nguyên bản có đầy đủ dấu câu, nhưng cỗ máy học (TF-IDF & FAISS) thì chỉ rà quét trên trục content hoàn toàn tinh khiết, với tên người đã được đúc thành khối (dir_..., cast_...) và tiêu đề inception được lập lại 2 lần để kích xung trọng số bắt từ khóa.

4.2. Thiết lập các cài đặt

Để quá trình đánh giá và thực nghiệm diễn ra khách quan, cấu hình không gian vector biểu diễn đặc trưng ngôn ngữ của hệ thống được cố định bằng một tập các "siêu tham số" (Hyperparameters). Đây là các cấu hình được đúc kết thông qua nhiều vòng tinh chỉnh thử sai (Trial and Error) để đạt được trạng thái tối ưu nhất giữa thời gian tính

toán và độ chuẩn xác của truy hồi.

Khung thiết lập hệ thống được quy định chi tiết trong Bảng dưới đây:

Nhóm chức năng	**Tên Cài đặt / Cấu hình thuật toán**	**Giá trị thiết lập**
Không gian Từ vựng (TF-IDF)	Giới hạn từ vựng (max_features)	10.000
	Tập từ dừng (stop_words)	Tham số chuẩn "english"
	Độ rải phân mảnh từ (ngram_range)	Biểu thức (1, 2)
Không gian Mạng LSA (Truncated SVD)	Số chiều giảm tải (n_components)	300
	Hàm cố định trạng thái sinh ngẫu nhiên (random_state)	Cố định 42
Đánh chỉ mục Không gian (FAISS)	Thuật toán cấu trúc gốc (IndexFlatIP)	Inner Product
	Hàm chuẩn hóa Vector trước khi nạp	faiss.normalize_L2

Giải thích lựa chọn cho các thiết lập:

1. Khấu hình Không gian Từ vựng (TF-IDF)

- max_features = 10000 (Giới hạn từ khóa): Ngữ liệu gốc có hàng trăm ngàn từ vựng khác nhau. Nếu nạp toàn bộ, bộ nhớ phân bổ của máy chủ sẽ bị tràn (Out of Memory). Hệ thống chủ đích cắt bỏ phần đuôi nhiễu (Long-tail noise), chỉ giữ lại 10.000 từ khóa mang giá trị phân loại cao nhất.
- ngram_range = (1, 2) (Độ phủ n-gram): Cho phép thuật toán quét cả từ đơn (Unigram: "Star") và cụm 2 từ liền kề (Bigram: "Star Wars"). Điều này cực kỳ quan

trọng để máy học không "viết chú giải sai" các cụm danh từ riêng đặc thù như "iron_man", "black_hole". Giới hạn tối đa ở mức 2 nhằm ngăn chặn ma trận phình to theo cấp số nhân.

2. Cấu hình Không gian Ngữ nghĩa LSA

- n_components = 300 (Số chiều thu gọn): Đây là mốc số chiều "Tỷ lệ vàng" kinh điển trong ngành Xử lý ngôn ngữ tự nhiên. Việc ép nén có chủ đích:
- Khắc phục lỗi chiều thấp: Nếu nén < 100 chiều, các ý nghĩa bị dồn ép quá mức gây "ảo giác" (nhầm phim Kinh dị thành phim Hài kịch).
- Khắc phục lỗi chiều cao: Nếu nén > 1000 chiều, vector bị loãng và mất đi sức mạnh gom cụm từ đồng nghĩa. Trục 300 chiều giúp mô hình giữ lại mức thông tin cốt lõi (Explained Variance) hoàn hảo nhất.

3. Cấu hình Mạng quét Vector FAISS

- Thủ thuật normalize_L2 kết hợp IndexFlatIP: Mục tiêu của mô hình là đo khoảng cách Cosine (Cosine Similarity) để tìm ra bộ phim giống với câu truy vấn nhất. Tuy nhiên, công thức Cosine gốc có chứa phép chia mẫu số, gây tổn hao cực lớn cho CPU khi quét hàng chục nghìn bộ phim.
- Giải pháp đánh lừa Toán học: Hệ thống được lập trình ép chuẩn hóa toàn bộ ma trận LSA về độ dài Unit = 1 (normalize_L2). Dựa trên tính chất Đại số tuyến tính, lúc này phép tính Tích vô hướng đơn giản (IndexFlatIP) sẽ cho ra kết quả trùng khớp 100% với phép đo Cosine. Kỹ thuật này giúp bộ máy đạt ngưỡng phản hồi theo thời gian thực (Mili-giây) mà không hy sinh bất kỳ % độ nét nào.

4.3. Đánh giá mô hình

4.3.1. Phương pháp đánh giá

Hệ thống được đánh giá theo hướng **Information Retrieval (IR Evaluation)** thông qua việc sử dụng một tập truy vấn kiểm thử (query set) và tập kết quả kỳ vọng (ground

truth).

Thay vì sử dụng dữ liệu được gán nhãn thủ công, đề tài áp dụng phương pháp xây dựng **ground truth theo heuristic**, dựa trên chính các thuộc tính có sẵn trong cơ sở dữ liệu phim như tên phim, đạo diễn, diễn viên và thể loại. Cách tiếp cận này mang lại một số lợi ích:

- Tạo được số lượng lớn truy vấn kiểm thử một cách tự động
- Bao phủ nhiều loại ý định tìm kiếm khác nhau
- Phù hợp với đặc trưng của bài toán hệ thống tìm kiếm thực tế
- Giảm chi phí gán nhãn thủ công

Tổng cộng 200 truy vấn được sinh ra và chia thành các nhóm chính:

- **Semantic/Plot**: truy vấn theo nội dung hoặc ngữ nghĩa của phim (ví dụ: "space time travel wormhole")
- **Director**: truy vấn theo đạo diễn (ví dụ: "directed by Nolan")
- **Actor**: truy vấn theo diễn viên (ví dụ: "starring Tom Hanks")
- **Genre**: truy vấn theo thể loại (ví dụ: "best action movies")
- **Partial Title**: truy vấn dựa trên một phần tên phim

4.3.2. Các độ đo sử dụng

Để đánh giá hiệu quả của hệ thống truy hồi, đề tài sử dụng các chỉ số phổ biến trong IR, được tính tại ngưỡng K=10:

- **Precision@K**: Đo tỷ lệ các kết quả đúng trong top-K kết quả trả về
- **Recall@K**: Đo khả năng hệ thống tìm được các kết quả đúng trong toàn bộ tập ground truth
- **HitRate@K**: Xác định liệu trong top-K có ít nhất một kết quả đúng hay không
- **MRR (Mean Reciprocal Rank)**: Đánh giá vị trí của kết quả đúng đầu tiên trong danh sách xếp hạng

- **NDCG@K (Normalized Discounted Cumulative Gain)**: Đánh giá chất lượng xếp hạng có xét đến vị trí của các kết quả đúng
- **Latency (ms)**: Thời gian phản hồi trung bình của hệ thống cho mỗi truy vấn

Các chỉ số này giúp đánh giá toàn diện cả về độ chính xác, chất lượng xếp hạng và hiệu năng hệ thống.

4.3.3. Kịch bản so sánh mô hình

Để đánh giá hiệu quả của phương pháp Hybrid Search, hệ thống được triển khai và so sánh trên ba cấu hình khác nhau:

- **TF-IDF thuần (α = 1.0)**: Chỉ sử dụng phương pháp khớp từ khóa (lexical matching), không xét đến ngữ nghĩa.
- **LSA/FAISS thuần (α = 0.0)**: Chỉ dựa trên không gian ngữ nghĩa (semantic matching), khai thác mối quan hệ ẩn giữa các từ và tài liệu.
- **Hybrid (α = 0.5)**: Kết hợp cả hai phương pháp TF-IDF và LSA nhằm cân bằng giữa khớp từ khóa và hiểu ngữ nghĩa.

Điểm số của mô hình Hybrid được tính theo công thức:

$$Score_{hybrid} = \alpha \cdot Score_{TFIDF} + (1 - \alpha) \cdot Score_{LSA}$$

Trong đó, α là tham số điều chỉnh mức độ ảnh hưởng của từng thành phần.

Sau bước truy hồi ban đầu, hệ thống tiếp tục áp dụng **re-ranking** nhằm tối ưu thứ tự kết quả dựa trên các yếu tố bổ sung như:

- Độ tương đồng (similarity)
- Điểm đánh giá trung bình của phim (rating)
- Mức độ phổ biến (popularity)

Cơ chế này giúp cải thiện chất lượng xếp hạng cuối cùng, đặc biệt trong các trường hợp có nhiều kết quả liên quan.

4.4. Kết quả thực nghiệm

4.4.1. Kết quả tổng quan

Kết quả đánh giá trên tập 150 truy vấn được tổng hợp trong bảng sau:

Table 4. Bảng so sánh hiệu năng giữa các mô hình

Mô hình	Latency (ms)	MRR	Precision (%)	Recall (%)	HitRate (%)	NDCG (%)
TF-IDF thuần	26.0	0.4176	20.81	53.87	64.00	42.61
LSA thuần	23.4	0.2089	5.00	10.92	24.67	11.40
Hybrid (TF-IDF + LSA)	24.0	0.2710	14.80	33.52	44.00	25.82

Nhận xét:

- TF-IDF thuần cho kết quả tốt nhất về các độ đo Precision, Recall, HitRate và NDCG.
- LSA thuần có hiệu suất thấp nhất trên hầu hết các metric.
- Hybrid cải thiện đáng kể so với LSA, nhưng vẫn thấp hơn TF-IDF ở các chỉ số tổng thể.
- Độ trễ giữa các mô hình không chênh lệch đáng kể (khoảng 23–26 ms), đảm bảo khả năng phản hồi thời gian thực.

4.4.2. Phân tích theo loại truy vấn (Hybrid model)

Kết quả đánh giá theo từng nhóm truy vấn được thể hiện như sau:

Table 5. Hiệu năng theo loại truy vấn

Loại truy vấn	MRR	HitRate (%)
Semantic/Plot	0.5417	66.67
Director	0.1557	25.00
Actor	0.4783	68.75
Partial Title	0.1450	35.42

Nhận xét:

- Nhóm Semantic/Plot đạt hiệu quả cao nhất, cho thấy mô hình xử lý tốt các truy vấn mang tính ngữ nghĩa.
- Nhóm Actor cũng cho kết quả tốt do có sự kết hợp giữa thông tin nội dung và metadata.
- Nhóm Director và Partial Title có hiệu suất thấp hơn, do các truy vấn này yêu cầu khớp chính xác hoặc bị thiếu thông tin đầy đủ.

4.4.3. Đánh giá chung

- TF-IDF phù hợp với các truy vấn có từ khóa rõ ràng, mang tính exact matching.
- LSA hỗ trợ tốt cho truy vấn ngữ nghĩa nhưng chưa đủ mạnh khi sử dụng độc lập.
- Hybrid giúp cân bằng giữa hai phương pháp và cải thiện hiệu quả trên nhiều loại truy vấn khác nhau.
- Hệ thống có độ trễ thấp (~24 ms), phù hợp với yêu cầu tìm kiếm gần thời gian thực.

4.5. Phân tích và thảo luận kết quả

4.5.1. So sánh giữa các mô hình

Từ kết quả thực nghiệm, có thể nhận thấy sự khác biệt rõ rệt giữa ba mô hình:

- **TF-IDF thuần** đạt hiệu quả cao nhất trên hầu hết các chỉ số (MRR, Precision, Recall, HitRate, NDCG). Điều này cho thấy phương pháp dựa trên từ khóa vẫn hoạt động rất tốt đối với dữ liệu phim, đặc biệt khi truy vấn chứa các thuật ngữ rõ ràng

hoặc trùng khớp trực tiếp với nội dung.

- **LSA thuần** cho kết quả thấp nhất. Nguyên nhân có thể do:
  - Không gian ngữ nghĩa chưa được biểu diễn đủ tốt với dữ liệu hiện tại
  - Một số truy vấn yêu cầu khớp chính xác (exact match), trong khi LSA thiên về semantic similarity → Dẫn đến việc ranking chưa phản ánh đúng mức độ liên quan trong nhiều trường hợp.

- **Hybrid (TF-IDF + LSA)** đạt kết quả trung gian. Mô hình này cải thiện đáng kể so với LSA thuần, tuy nhiên chưa vượt qua TF-IDF ở các metric tổng thể. Điều này cho thấy việc kết hợp hai phương pháp giúp tăng khả năng truy hồi, nhưng mức đóng góp của semantic chưa đủ lớn để vượt TF-IDF trong bộ dữ liệu này.

4.5.2. Đánh giá về hiệu năng hệ thống

- **Latency** của các mô hình dao động từ 23–26 ms, cho thấy hệ thống có khả năng phản hồi nhanh và phù hợp với các ứng dụng tìm kiếm thời gian thực.
- Việc sử dụng FAISS giúp tối ưu quá trình truy hồi vector, giảm đáng kể thời gian tính toán.
- Sự chênh lệch latency giữa các mô hình không đáng kể, chứng tỏ chi phí kết hợp Hybrid không ảnh hưởng nhiều đến hiệu năng.

4.5.3. Nhận xét tổng hợp

Từ các kết quả thực nghiệm, có thể rút ra một số nhận xét chính:

- TF-IDF là lựa chọn hiệu quả cho các truy vấn mang tính từ khóa rõ ràng.
- LSA giúp mở rộng khả năng hiểu ngữ nghĩa nhưng chưa đủ mạnh khi sử dụng độc lập.
- Hybrid mang lại sự cân bằng giữa lexical matching và semantic matching, giúp cải thiện hiệu quả trong nhiều loại truy vấn.

- Không có mô hình nào tối ưu tuyệt đối cho tất cả các loại query, do đó việc kết hợp nhiều phương pháp là cần thiết trong bài toán tìm kiếm thực tế.
- Hệ thống đạt hiệu năng tốt cả về chất lượng truy hồi và thời gian phản hồi.

CHƯƠNG 5. KẾT LUẬN

5.1. Nhận xét kết quả đề tài

Đề tài đã xây dựng thành công một hệ thống tìm kiếm phim dựa trên các phương pháp truy hồi thông tin hiện đại, bao gồm TF-IDF, LSA và mô hình Hybrid kết hợp cả hai phương pháp.

Thông qua quá trình thực nghiệm với tập 150 truy vấn kiểm thử, hệ thống đã đạt được các kết quả chính như sau:

- Hệ thống có khả năng truy hồi và xếp hạng kết quả với độ chính xác tương đối tốt, đặc biệt với mô hình TF-IDF.
- Mô hình Hybrid giúp cải thiện hiệu quả so với LSA thuần và mang lại sự cân bằng giữa matching từ khóa và matching ngữ nghĩa.
- Hệ thống hoạt động ổn định với thời gian phản hồi trung bình khoảng 24 ms, đáp ứng yêu cầu tìm kiếm gần thời gian thực.
- Kết quả theo từng nhóm truy vấn cho thấy hệ thống hoạt động tốt với các truy vấn semantic và actor, nhưng còn hạn chế với các truy vấn dạng metadata chính xác như director hoặc partial title.

Nhìn chung, đề tài đã đạt được mục tiêu xây dựng một hệ thống tìm kiếm có khả năng mở rộng, kết hợp được nhiều phương pháp và đánh giá theo tiêu chuẩn IR.

5.2. Ưu – nhược điểm của đề tài

5.2.1. Ưu điểm

- Áp dụng được nhiều phương pháp truy hồi thông tin hiện đại (TF-IDF, LSA, Hybrid).
- Có cơ chế đánh giá đầy đủ với các metric IR phổ biến như Precision, Recall, MRR, NDCG.
- Ground truth được xây dựng tự động giúp mở rộng số lượng truy vấn kiểm thử.

- Hệ thống có kiến trúc rõ ràng, dễ mở rộng và tích hợp thêm các phương pháp khác.
- Đảm bảo hiệu năng tốt với thời gian phản hồi thấp.

5.2.2. Nhược điểm

- Ground truth được xây dựng theo heuristic nên chưa phản ánh đầy đủ toàn bộ mức độ liên quan thực tế.
- Mô hình LSA còn hạn chế trong việc biểu diễn ngữ nghĩa sâu với dữ liệu phim.
- Chưa áp dụng các mô hình học sâu (deep learning) như embedding-based retrieval (BERT, Sentence Transformers).
- Cơ chế reranking còn đơn giản, chủ yếu dựa trên similarity, rating và popularity.

5.3. Hướng phát triển

Trong tương lai, hệ thống có thể được cải tiến theo các hướng sau:

- Tích hợp các mô hình embedding hiện đại như BERT hoặc Sentence Transformers để cải thiện khả năng hiểu ngữ nghĩa.
- Áp dụng các phương pháp learning-to-rank để tối ưu hóa bước reranking.
- Cải thiện cơ chế xây dựng ground truth bằng cách kết hợp thêm dữ liệu gán nhãn thủ công hoặc dữ liệu người dùng thực tế.
- Mở rộng hệ thống sang kiến trúc production-ready với API và giao diện người dùng (web UI).
- Tối ưu hóa thêm hiệu năng truy vấn khi mở rộng dữ liệu lớn hơn.
- Kết hợp thêm các tín hiệu hành vi người dùng (click-through data, rating) để nâng cao chất lượng đề xuất.

TÀI LIỆU THAM KHẢO

[1] Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.

[2] Baeza-Yates, R., & Ribeiro-Neto, B. (2011). *Modern Information Retrieval: The Concepts and Technology behind Search*. Addison-Wesley.

[3] Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523.

[4] Deerwester, S., Dumais, S. T., Furnas, G. W., Landauer, T. K., & Harshman, R. (1990). Indexing by latent semantic analysis. *Journal of the American Society for Information Science*, 41(6), 391–407.

[5] Robertson, S. E., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333–389.

[6] Schütze, H., Manning, C. D., & Raghavan, P. (2008). *Introduction to Information Retrieval* (Chapters on evaluation metrics such as Precision, Recall, MRR, NDCG). Cambridge University Press.

[7] Van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605. *(tham khảo cho kỹ thuật biểu diễn vector/embedding)*

[8] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[9] Facebook AI Similarity Search (FAISS). (n.d.). *FAISS Library Documentation*. https://github.com/facebookresearch/faiss

[10] MovieLens Dataset. GroupLens Research. https://grouplens.org/datasets/movielens/